

Project Technical Architecture

Le présent document détaille l'architecture technique proposée pour un système Agentic Hybrid RAG (Retrieval Augmented Generation) sécurisé et fiable. Ce système est conçu pour faciliter l'accès et la compréhension de contenus réglementaires et juridiques validés par des utilisateurs non experts. Il intègre des mécanismes avancés de récupération, de génération et de sécurité pour garantir la précision, la traçabilité et la maintenabilité des informations.

1) Objective

L'objectif principal est la construction d'un système Agentic Hybrid RAG sécurisé et fiable, visant à aider les utilisateurs non experts à récupérer et à comprendre du contenu réglementaire/légal validé. Les priorités fondamentales du système sont les suivantes :

- Précision : Atteinte par une combinaison de récupération hybride, de reranking avancé et d'une application stricte de la citation des sources.
- Traçabilité : Assurée par le suivi des sources et un système de versioning rigoureux du contenu et de ses métadonnées.
- Sécurité : Maintenue par une surveillance proactive des tentatives d'injection de prompt et d'empoisonnement des données.
- Maintenabilité : Garanti par une architecture orientée objet (OOP), une conception en microservices et une stratégie de test exhaustive.

2) Global System Flow

Le flux global du système est structuré en deux cycles principaux, couvrant la gestion des données et le traitement des requêtes.

A) Data Lifecycle (Governed Ingestion)

Le cycle de vie des données décrit le processus d'ingestion contrôlée du contenu.

1. Collecte en ligne : Le contenu est collecté par scraping à partir de sources considérées comme fiables et validées.
2. Validation humaine : Des experts sont impliqués dans un workflow de validation, où ils peuvent approuver, rejeter ou marquer le contenu comme en attente (pending).
3. Prétraitement et enrichissement des métadonnées : Le contenu est nettoyé, normalisé et enrichi avec des métadonnées pertinentes.
4. Découpage (Chunking) et stratégie de chevauchement : Le contenu est divisé en blocs (chunks) selon une stratégie configurable de chevauchement, dont la taille exacte sera ajustée empiriquement.
5. Génération d'embeddings : Le modèle d'embedding Gemini est utilisé pour générer des représentations vectorielles (embeddings) des chunks.
6. Stockage :
 - Les embeddings sont stockés dans Weaviate, utilisant un index HNSW (Hierarchical Navigable Small Worlds) pour une recherche efficace.
 - Un index lexical est également stocké pour le moteur de recherche BM25.
7. Versioning et traçabilité :
 - Les entrées correspondantes dans la base de données vectorielle sont mises à jour ou invalidées en fonction des changements de version des documents sources.

B) Query Lifecycle (Hybrid Agentic RAG)

Le cycle de vie des requêtes gère la réception d'une question utilisateur jusqu'à la génération d'une réponse.

1. Entrée utilisateur : L'utilisateur soumet une question, soit textuellement, soit via une interface de reconnaissance vocale (speech-to-text).
2. Réécriture et expansion de la requête : La requête initiale est réécrite et enrichie pour améliorer la pertinence de la recherche, en utilisant le modèle Gemini.
3. Récupération hybride : Une approche combinée est utilisée pour la récupération des informations.
 - Récupération lexicale BM25 : Utilisation d'un index BM25 pour la correspondance par mots-clés.
 - Récupération vectorielle : Recherche de similarité cosinus sur les embeddings dans la base de données vectorielle.

- Fusion : Les résultats des deux méthodes de récupération sont combinés de manière robuste en utilisant le mécanisme Reciprocal Rank Fusion (RRF).
4. Reranking par lots par LLM : Les candidats les mieux classés issus de la fusion sont soumis à un reranking par lots effectué par un grand modèle de langage (LLM) pour affiner leur pertinence.
5. Génération augmentée : La réponse est générée avec les principes suivants :
- Dérivation exclusive : La réponse doit être exclusivement dérivée des preuves récupérées.
 - Summarisation : Une synthèse est incluse si nécessaire.
 - Enforcement de la citation : La réponse doit obligatoirement inclure les sources, les citations directes et les ancres vers les chunks récupérés.
6. Feedback utilisateur : Les signaux de feedback de l'utilisateur (j'aime/je n'aime pas) sont enregistrés pour l'évaluation et l'ajustement futurs du système.

3) Chunking & Preprocessing (Planned Strategy)

La stratégie de découpage et de prétraitement est essentielle pour optimiser la qualité des embeddings et la pertinence de la récupération.

- Prétraitement : Le processus inclut la tokenisation, la lemmatisation, la racinisation et la suppression des mots vides (stopwords) lorsque cela est pertinent.
- Approche de découpage :
 - Une approche de type "interaction tardive / concept de découpage tardif" inspirée de ColBERT est adoptée pour une plus grande précision de récupération.
 - Une stratégie de chevauchement est activée (Overlap), dont la taille exacte sera déterminée empiriquement après des tests et des ajustements.
 - Un découpage manuel est prévu pour gérer les formats complexes ou "piégeux" tels que les articles juridiques, les annexes et autres contenus structurés.
- Gestion des tableaux et listes à puces : Ces éléments seront initialement traités comme des blocs de texte structurés. La stratégie de parsing sera affinée en fonction des erreurs observées et suivies via l'analyse des erreurs et les tests unitaires.

4) Retrieval Core (Hybrid Search)

Le cœur de la récupération s'appuie sur une recherche hybride combinant des approches lexicales et sémantiques, puis une fusion des résultats.

- Lexical : Un index BM25 est utilisé pour la correspondance basée sur les mots-clés, offrant une récupération efficace des documents pertinents par leur contenu textuel direct.
- Sémantique :
 - Les embeddings générés par le modèle Gemini sont comparés en utilisant la similarité cosinus.
 - Weaviate avec son index HNSW (Hierarchical Navigable Small Worlds) est utilisé pour des recherches de voisins les plus proches approximatifs rapides et efficaces.
- Fusion : Le mécanisme de Reciprocal Rank Fusion (RRF) est appliqué pour combiner de manière robuste les résultats de la recherche lexicale (BM25) et sémantique (vectorielle), produisant un classement unifié.

5) Reranking

Le reranking constitue une étape cruciale pour affiner la précision des résultats de la recherche.

- LLM batch reranking : Un processus de reranking par lots est effectué par un Grand Modèle de Langage (LLM) sur les k meilleurs résultats fusionnés.
- Objectif : L'objectif principal est d'améliorer la précision des résultats de récupération et de réduire la présence de chunks "presque pertinents" dans l'ensemble final de preuves.

6) Generation & Grounding

La phase de génération et d'ancrage est responsable de la création de la réponse finale, en s'assurant de sa fidélité aux preuves récupérées.

- Base LLM : L'API Gemini est utilisée comme modèle de langage de base pour plusieurs fonctions :
 - Réécriture et expansion de requêtes.
 - Génération des réponses.
 - Summarisation du contenu si nécessaire.
- Règles d'ancrage (Grounding rules) :

- Génération augmentée par récupération seulement : La réponse générée doit être strictement dérivée des chunks récupérés. Elle ne doit pas introduire d'informations externes.
- Gestion de l'insuffisance de preuves : Si les preuves récupérées sont insuffisantes pour formuler une réponse complète et factuelle, le système doit soit demander une clarification à l'utilisateur, soit refuser de répondre de manière sûre (refusal safely).
- Fallback : Un mécanisme de fallback est implémenté :
 - Un LLM de secours est activé en cas d'échec de l'API Gemini (par exemple, suite à des timeouts, des limites de débit atteintes ou d'autres erreurs).

7) Agentic Features

Le système intègre des fonctionnalités agentiques pour une gestion intelligente et sécurisée des interactions.

Admin Agent (Tool Use)

L'Agent Administrateur permet aux administrateurs de gérer la base de connaissances via des commandes en langage naturel et des appels d'outils sécurisés.

- Gestion des documents :
 - Ajouter un document.
 - Supprimer un document.
 - déclencher un ré-embedding.
 - Attacher des notes ou des métadonnées de validation.

User Agent

L'Agent Utilisateur facilite des interactions utilisateur plus complexes et dynamiques.

- RAG récursif : Capacité à effectuer des récupérations multi-étapes lorsque la complexité de la requête l'exige.
- Boucle de clarification : Engage une boucle de clarification avec l'utilisateur si la requête est jugée ambiguë.

Guardrails

Des garde-fous sont mis en place pour assurer la sécurité et la stabilité du système.

- Contrôle d'accès basé sur les rôles (RBAC) : L'accès aux outils est strictement contrôlé par RBAC, garantissant que seuls les utilisateurs autorisés peuvent exécuter certaines actions.
- Limites de profondeur récursives : Des limites sont imposées à la profondeur des appels récursifs pour éviter les boucles infinies et une consommation excessive de ressources.

8) Security Layer

La couche de sécurité est conçue pour atténuer les menaces clés et protéger l'intégrité du système et des données.

Menaces traitées

- Injection de prompt : Protection contre les tentatives de manipulation du comportement du LLM via des entrées malveillantes.
- Empoisonnement des données (Data poisoning) : Défense contre l'introduction de données falsifiées ou erronées dans la base de connaissances.
- Fuite d'informations sensibles : Prévention de la divulgation non autorisée de données confidentielles.

Contrôles

- Authentification et RBAC : Mise en œuvre de mécanismes robustes d'authentification et de contrôle d'accès basé sur les rôles pour réguler l'accès au système et aux fonctionnalités.
- Assainissement des entrées et durcissement des prompts : Application de techniques d'assainissement rigoureuses pour toutes les entrées utilisateur et des stratégies de durcissement (hardening) pour les prompts afin de minimiser les vulnérabilités.
- Tableau de bord de surveillance de type SIEM (optionnel) : Un tableau de bord de surveillance inspiré des systèmes SIEM peut être mis en œuvre pour :
 - Générer des alertes de détection en temps réel.
 - Surveiller les anomalies (par exemple, des modèles d'ingestion ou de requêtes suspects).
- Journaux d'audit : Enregistrement détaillé de toutes les actions administratives à des fins de traçabilité et d'analyse forensique.

9) Architecture (Microservices)

L'architecture est basée sur une approche microservices, favorisant la modularité, la scalabilité et la maintenabilité.

- Backend : Développé en Python FastAPI avec Uvicorn, en suivant les principes de la Programmation Orientée Objet (OOP) à travers tous les services.

Services proposés

- Auth Service : Gère l'authentification des utilisateurs, la gestion des tokens et le contrôle d'accès basé sur les rôles (RBAC).(supabase Relational Database)
- Ingestion Service : Responsable du processus de scraping et du workflow de validation par les experts.
- Preprocessing/Embedding Service : Effectue le nettoyage du contenu, le découpage en chunks, la génération des embeddings et l'indexation.
- Retrieval Service : Gère la récupération BM25, la récupération vectorielle et la fusion des résultats via RRF.
- Reranking Service : Exécute le reranking par lots des candidats par le LLM.
- Generation Service : Utilise l'API Gemini pour la génération des réponses, l'application des citations et gère le modèle de fallback.
- Admin Service : Fournit les fonctionnalités du panneau d'administration et gère les appels d'outils.
- Security Service : Effectue les tests et la surveillance de l'injection de prompt et gère les journaux d'audit.
- Feedback Service : Stocke les signaux de feedback (like/dislike) et gère les mises à jour des jeux de données d'évaluation.

Caching

- Redis : Utilisé pour la mise en cache des embeddings, des requêtes répétées et des résultats de récupération fréquents afin d'améliorer les performances et réduire la latence.

Frontend

- ReactJS : La technologie ReactJS est utilisée pour le développement des interfaces utilisateur, notamment :
 - Un panneau utilisateur pour les interactions standard.
 - Un panneau d'administration pour la gestion du système.
 - Un tableau de bord de sécurité pour la surveillance.

10) Evaluation & Testing

Une stratégie rigoureuse d'évaluation et de test est fondamentale pour assurer la qualité et la fiabilité du système.

Évaluation

- Jeu de données "Golden" : Un jeu de données de référence "golden" est maintenu pour l'évaluation.
- Métriques de base : Utilisation de métriques standards telles que la précision (Precision), le rappel (Recall) et le score F1.
- Métriques de récupération optionnelles : Des métriques plus avancées comme MRR (Mean Reciprocal Rank), nDCG (Normalized Discounted Cumulative Gain) et Recall@k peuvent être utilisées.
- Évaluation basée sur le LLM (optionnel) : Une évaluation peut être réalisée à l'aide d'un LLM pour mesurer la fidélité (faithfulness), l'ancrage (grounding) et l'utilité (helpfulness) des réponses générées.

Tests

- Tests unitaires : Couvrent des composants individuels tels que le prétraitement, le découpage, la fusion de récupération et la pipeline de reranking.
- Tests d'intégration : Valident le bon fonctionnement de l'ensemble de la chaîne RAG de bout en bout.
- Tests de sécurité : Des tests spécifiques sont mis en œuvre pour valider la robustesse du système face aux menaces :
 - Suite de tests d'injection de prompt.
 - Requêtes adversariales simulant des attaques.
 - Simulations d'empoisonnement des données (optionnel).

11) Error Analysis & Observability

L'analyse des erreurs et l'observabilité sont des composants centraux pour le diagnostic rapide et la résolution des problèmes.

- Journalisation pour chaque étape : Des journaux détaillés sont générés à chaque étape du processus :
 - Sorties du prétraitement.
 - Candidats de récupération et leurs scores.
 - Classement de la fusion.
 - Sorties du reranking.

- Réponse finale et citations associées.
- Objectif : L'objectif est d'identifier rapidement la cause première d'une défaillance, qu'elle soit due à :
 - Un problème d'ingestion ou de formatage.
 - Un problème de découpage (chunking).
 - Une inadéquation de récupération.
 - Un échec du reranking.
 - Un risque d'hallucination de la génération.